

왜 '그냥 평균'이 아니라
로버스트 베이지안 인가

제주 유역 지하수위 '대표값' 산정법 해설

Student-t 가능도 계층모형(robust Bayes)이 무엇을, 왜, 어떻게 하는지 — 그림으로 이해하기

16개 유역 · 177개 관측정 · 2026-06-07

한 장 요약 — 세 가지 문제, 하나의 해법

이상치 1개

1

변동성 큰 관측소 1개가 단순평균을 끌고 감

관측소 누락 (N_drop)


2

조천 2026-05: 1개 빠지자 8.27 → 2.72 m 급락

표고 이질성

3

한 유역 안 13 m ~ 363 m 절대수위 평균은 무의미



로버스트 베이지안 (방법 F)

세 문제를 동시에 푸는 단일 최적안

두꺼운 꼬리(Student-t)

①

이상치·급변 관측소를 자동으로 약하게 반영

계층 수축(shrinkage)

②

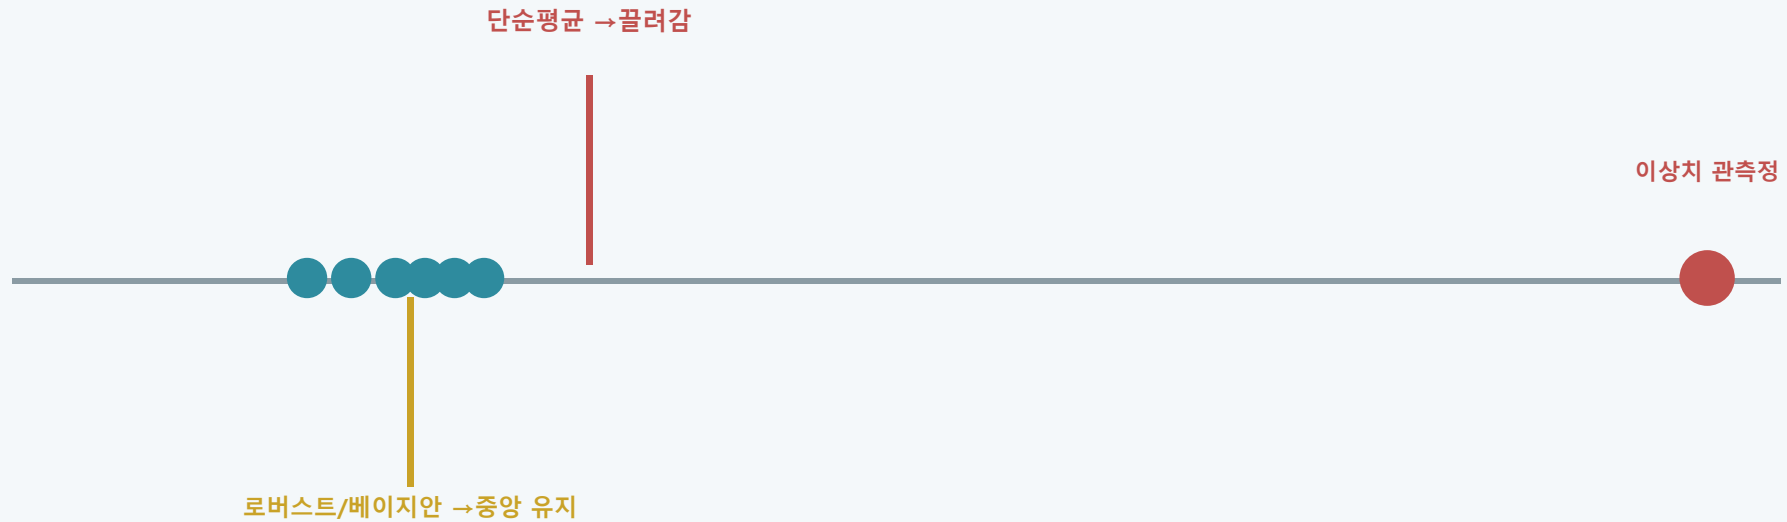
관측정 적은 유역을 섬 전체 평균으로 끌어 안정화

불확실성 제공

③

점추정이 아니라 신뢰구간까지 산출

1 문제 1. 단순평균은 이상치 1개에 끌려간다




핵심:

단순평균은 모든 관측점에 똑같은 가중치(1)를 줍니다. 그래서 멀리 떨어진 값 하나가 대표값 전체를 흔듭니다.
로버스트 베이지안은 '중심에서 먼 값일수록 가중치를 자동으로 줄여' 이상치의 영향을 억제합니다.

2 문제 2. 관측소 1개 누락이 유역 수위를 '급락'시킨다

실제 사례 — 조천 유역 (2026년)



해법


관측소 집합이 바뀐 달의 평균은 '같은 유역 상태'가 아닙니다.

F는 관측소별 '자기 과거 대비 변화량'을 쓰므로 빠진 관측소가 자동 제외되고,

두꺼운 꼬리로 급변값도 억제 → 가짜 급락이 사라집니다.

3 문제 3. 한 유역 안에서도 표고가 천차만별

예: 서서귀 유역 6개 관측정의 평균 지하수위(EL)



절대수위(13 m와 363 m)를 그냥 평균하면 '구성'이 평균을 지배합니다. 그래서 변동량은 '관측정별 자기 과거 대비 변화량'으로 계산해야 표고 차이가 상쇄됩니다.

해결의 출발점 — 관측정마다 '자기 과거 대비 변화량'

① 관측정 단위 변환

변화량 = (이번달 수위) - (직전 3년 같은 달, 그 관측정의 평균)

- 표고가 높은 낮은 '자기 자신'과 비교 → 표고 차이 상쇄
- 과거 자료 없는(새로/빠진) 관측정은 자동 제외 → N_drop 해결

관측정 A (저지대)

+0.4 m

관측정 B (고지대)

-0.2 m

관측정 C

+0.1 m



② 유역 단위 집계 — 6가지 방법

A 정규화

단순평균

B 분산가중

$1/\sigma^2$ 로 가중

C 패널균형

공통 관측정만

D 로버스트

Biweight, 이상치 저항

E 베이지안

계층 수축

F 로버스트베이지안

D+E 결합 (최적)


‘평균’에서 ‘로버스트 베이지안’까지 — 진화의 6단계



→ 각 단계는 앞 단계의 약점을 보완합니다. 마지막 F는 D(이상치 저항)와 E(소표본 안정)를 합치고 불확실성까지 제공합니다.

A 방법 A · 정규화 (N_drop 자동 제외)

관측정 변화량 $a_i = (\text{이번달 수위}) - (\text{직전 3년 같은 달, 그 관측정 평균}) \rightarrow \text{유역값 산출 방식}$



이렇게 측정한다

핵심 정의

모든 관측정 변화량을 똑같은 비중으로 단순 평균. 변화량 정의상 과거·현재가 모두 있는 관측정만 들어와, 빠진 관측정은 저절로 빠집니다.

유역값 계산

유역값 = 평균($a_1, a_2, \dots, a_n$) (가중치 모두 1)

장점

가장 쉽고 직관적·즉시 적용. 관측소 누락(N_drop) 자동 보정.

단점·주의

변동성 큰 관측정의 영향이 그대로 남고, 불확실성(신뢰구간)이 없음.


안정성(편차 sd) : 2.84

추천 용도 : 실시간 기본·입문

B

방법 B · 분산가중 ($1/\sigma^2$)

관측정 변화량 $a_i = (\text{이번달 수위}) - (\text{직전 3년 같은 달, 그 관측정 평균}) \rightarrow$ 유역값 산출 방식



이렇게 측정한다

핵심 정의

관측정마다 '평소 변동성(σ)'을 재고, 흔들림이 큰 관측정에는 작은 가중치를 줍니다. 안정적인 관측정의 목소리를 크게 듣는 방식.

유역값 계산

$$\text{유역값} = \frac{\sum(w_i \cdot a_i)}{\sum w_i}, \quad w_i = 1/\sigma_i^2$$

장점

불안정 관측정을 강하게 억제 $\rightarrow$ 가장 매끄럽고 안정적.

단점·주의

'절대수준 차이'와 '분산 차이'를 혼동할 수 있고, 실제 신호까지 과소반응할 위험.

안정성(편차 sd) : 0.66

추천 용도 : 안정성 최우선 보조지표

C 방법 C · 패널균형 (공통 관측정만)

관측정 변화량 $a_i = (\text{이번달 수위}) - (\text{직전 3년 같은 달, 그 관측정 평균}) \rightarrow \text{유역값 산출 방식}$

C. Keep only stations present in ALL periods

S1 -	✓	✓	✓	✓	USE
S2 -	✓	✓	✓	✓	USE
S3 -	✗	✓	✓	✓	drop
S4 -	✓	✓	✓	✓	USE
S5 -	✓	✗	✓	✓	drop
	Y-3	Y-2	Y-1	now	

이렇게 측정한다

핵심 정의

이번 달과 직전 3년에 '모두' 자료가 있는 관측정만 골라 평균. 매 시점 완전히 동일한 표본으로 비교하는 가장 엄격한 방식.

유역값 계산

유역값 = 평균(공통 관측정들의 a_i)

장점

표본 구성이 100% 동일 → 시점 간 비교가 가장 깨끗함.

단점·주의


한 관측정만 결측돼도 표본 수 N 이 급감 → 소수 유역에서 불안정.

안정성(편차 sd) : 2.99

추천 용도 : 표본 일관성 검증용

D 방법 D · 로버스트 (Biweight Trim)

관측정 변화량 $a_i = (\text{이번달 수위}) - (\text{직전 3년 같은 달, 그 관측정 평균}) \rightarrow \text{유역값 산출 방식}$



이렇게 측정한다

핵심 정의

Tukey Biweight로 '중앙에서 먼 값일수록 가중치를 줄여' 이상치 1~2개가 대표값을 끌고 가지 못하게 합니다.

유역값 계산

유역값 = Biweight 위치추정(a_i) (먼 값 weight ↓)

장점

이상치·센서 급변에 강건, 투명하고 빠름(ms급).

단점·주의

관측정 적은 유역의 '강도 차용'은 없고, 불확실성(신뢰구간) 미제공.


안정성(편차 sd) : 1.64

추천 용도 : 실시간 표시값 추천

E

방법 E · 베이지안 계층 (MCMC)

관측정 변화량 $a_i = (\text{이번달 수위}) - (\text{직전 3년 같은 달, 그 관측정 평균}) \rightarrow \text{유역값 산출 방식}$



이렇게 측정한다

핵심 정의

각 유역 추정치를 '섬 전체 평균' 쪽으로 끌어당기는 부분풀링. 표본이 적고 불확실한 유역일수록 더 많이 수축시켜 안정화합니다.

유역값 계산

$y_i \sim \text{Normal}(\theta_w, \sigma_w), \theta_w \sim \text{Normal}(\mu_{\text{섬}}, \tau) \rightarrow \theta_w \text{ 사후평균}$

장점

소표본 유역을 안정화하고 신뢰구간까지 제공.

단점·주의

정규 가정이라 '예외적으로 큰 참값'을 과도하게 수축할 수 있고 연산부하 있음.

안정성(편차 sd) : 1.36

추천 용도 : 월간 공식 보고

F 방법 F · 로버스트베이지안 — D와 E를 한 모형에 결합

D의 정신

두꺼운 꼬리(Student-t) 가능성도


→ 관측값 이상치를 자동으로 약하게 반영 (이상치 저항)

+

E의 정신

계층 사전분포(shrinkage)

→ 표본 적은 유역을 섬 전체 평균으로 수축 (소표본 안정)




F

로버스트베이지안

$$y_i \sim \text{Student-t}(v, \theta_w, \sigma_w) \quad \theta_w \sim \text{Normal}(\mu_{\text{섬}}, \tau) \quad \rightarrow \theta_w \text{의 사후평균} = \text{유역 변화량}$$

‘가능도(데이터를 보는 눈)’는 D처럼 두껍게, ‘사전분포(유역들을 묶는 끈)’는 E처럼 — 두 장치가 한 식 안에 함께 있습니다.




한 번에 두 가지가 일어납니다

- ① (D) 이상치 관측정은 두꺼운 꼬리로 영향력 ↓ → 가짜 급변 차단
- ② (E) 그렇게 정리된 유역값을 섬 평균으로 적절히 수축 → 소표본 안정
- ③ 게다가 '얼마나 확신하는지(신뢰구간)'까지 산출

결과: 안정성 sd 1.17 (E 1.36보다 안정) · PyMC와 MAE 0.045·상관 0.998 검증

로버스트 베이지안 핵심 ① — 두꺼운 꼬리(Student-t)




정규분포(E)는 꼬리가 얇아, 멀리 떨어진 값을 '있을 수 없는 일'로 보고 강하게 반응합니다.

Student-t(F)는 꼬리가 두꺼워, 가끔 나오는 큰 이상치를 '있을 수 있는 일'로 받아들입니다.

그 결과(아래 그림): 중심에서 먼 관측정일수록 가중치가 자동으로 줄어듭니다.

→ 센서 오류·일시 급변이 대표값을 흔들지 못합니다. '절사평균 / Biweight'의 장점을 통계모형 안에 내장한 샘플입니다.

로버스트 베이지안 핵심 ② — 계층 수축(shrinkage)





관측정이 3~5개뿐인 유역은 한 관측정만 튀어도 대표값이 불안정합니다.

계층모형은 각 유역 추정치를 '섬 전체 평균' 쪽으로 끌어당깁니다(점선).

- 표본이 적고 불확실한 유역일수록 더 많이 끌려옴(강한 수축)
- 표본이 많고 신뢰도 높은 유역은 거의 그대로 유지

왼쪽 그림: 빨강(단순평균) → 금색(로버스트 베이지안)으로 이동한 화살표가 '빌려온 안정성'입니다.

F가 실제로 한 일 — 더 안정적인 대표값



- 왼쪽: 같은 조천 2026-05 자료라도 방법에 따라 편차가 -1.61 m(REF) 에서 $-0.08\sim-0.53\text{ m(로버스트 계열)}$ 까지 달라집니다.
- 오른쪽: 전체 960셀의 편차 표준편차 — 안정성 순위는 $B\ 0.66 < F\ 1.17 < E\ 1.36 < D\ 1.64 < A\ 2.84 < C\ 2.99 < REF\ 3.89$.
- F는 베이지안(E)보다 더 안정적이면서도, 분산가중(B)과 달리 실제 신호를 과하게 죽이지 않아 '해석 타당성'이 가장 높습니다.

믿을 수 있나? — 독립 구현 교차검증 통과

우리가 만든 Gibbs MCMC 결과를 표준 라이브러리 PyMC(NUTS)와 비교

E · 베이지안(정규)

평균오차

0.052 m

상관계수

0.993

→ 사실상 동일 (구현 정확·재현 가능)

F · 로버스트베이지안(t)

평균오차

0.045 m

상관계수

0.998

→ 사실상 동일 (구현 정확·재현 가능)

· 16개 유역 전부 부호·크기 일치. 우리 구현이 검증된 베이지안 표준과 같은 답을 낸다는 의미입니다.

· F는 E보다 약간 무겁지만, 같은 정확도에 '이상치 저항'이 추가됩니다.

계산 전략 — 평소엔 빠르게, 일단위 분석만 다시 계산

제안하신 방식: 완료된 과거 월은 '미리 계산한 값'을 즉시 보여주고, 부분월(예: 6/7의 6일치)만 그때 다시 계산



완료된 월 (M-2 · M-1 · 완료 M) → 사전계산 캐시

월말에 한 번 F(로버스트 베이지안)를 계산해 저장. 대시보드는 저장값만 불러와 표시.
체감 소요시간 ≈ 0 (즉시). 평소 사용에는 추가 연산 부담이 없습니다.




부분월 (예: 6/7 → 6/1~6/6 6일치) → 요청 시 재계산

일자료가 매일 바뀌므로 이 슬롯만 그 자리에서 F를 다시 계산.
약 3초 대기 후 최신 수위 반영. '정밀한 일단위 분석'이 필요할 때만 기다리면 됩니다.

결과: 평상시 빠르고, 필요할 때만 정밀 — 연산 부담과 정확도를 모두 잡는 운영 방식

소요시간과 운영 권고



- 폐쇄형(REF·A·B·C·D): 3패널 5~11 ms — 즉시
- E 베이지안: 약 2.1초 / F 로버스트베이지안: 약 2.8초
- (단일 PC 실측, 데이터 로드 제외 / 캐시 시 최초 1회만)

실시간 표시값

D · 로버스트 (Biweight)

매 클릭 즉시(ms급). 이상치 저항.

완료 월 대표값

F · 사전계산 캐시

월 1회 계산 후 저장 → 즉시 표시.

부분월·일단위

F · 요청 시 재계산

약 3초 대기 후 최신 반영.

‘대표값’을 바꾸면, 보이는 수위가 달라진다

로버스트 베이지안(F)은 이상치에 흔들리지 않고, 관측정이 적은 유역도 안정적으로, 그리고 ‘얼마나 확신하는지’까지 함께 알려주는 대표값입니다.

평소엔 캐시로 즉시, 일단위 분석엔 재계산으로 정밀하게